

**INSTITUTO FEDERAL CATARINENSE – IFC
CAMPUS BRUSQUE
CURSO DE BACHARELADO EM SISTEMAS DE INFORMAÇÃO**

**ABRAÃO TEIXEIRA DA SILVA
BRENO DE BRITO ALVES
LUCAS SOUZA DE LIMA
PABLO MC COMB CELUCIO MARQUES**

**PROJETO DE PESQUISA: DESENVOLVER UMA FERRAMENTA IDS
BASEADA EM DEEP LEARNING.**

**BRUSQUE – SC
2026**

**ABRAÃO TEIXEIRA DA SILVA
BRENO DE BRITO ALVES
LUCAS SOUZA DE LIMA
PABLO MC COMB CELUCIO MARQUES**

**PROJETO DE PESQUISA: DESENVOLVER UMA FERRAMENTA IDS
BASEADA EM DEEP LEARNING.**

Artigo técnico-científico apresentado como requisito para a submissão e apresentação na IX Semana de Formação Acadêmica, Científica, Cultural e Humanística (IX FACCHU 2026) do Instituto Federal Catarinense – Campus Brusque.

Vínculo: Projeto de Pesquisa PVE2957-2025 ("IDS Deep Learning").

Orientador: Prof. Jackson Mallmann.

BRUSQUE – SC

2026

RESUMO

O crescimento exponencial do tráfego de dados em redes corporativas exige soluções de cibersegurança capazes de aliar mitigação em tempo real de baixa latência e alta capacidade de generalização na identificação de anomalias. Os Sistemas de Detecção e Prevenção de Intrusão (IDS/IPS) convencionais enfrentam gargalos severos de overhead na pilha de rede do sistema operacional e limitação na identificação de padrões relacionais complexos, como varreduras de portas e movimentação lateral de ameaças. Este trabalho apresenta o SPECTRE_GRID: UM SISTEMA DE DETECÇÃO E PREVENÇÃO DE INTRUSÃO HÍBRIDO BASEADO EM eBPF/XDP E REDES NEURAIIS EM GRAFO ESPAÇO-TEMPORAIS (STGNN). Uma arquitetura híbrida de IDS/IPS desenvolvida no âmbito do Projeto de Pesquisa PVE2957-2025 ("IDS Deep Learning") do Instituto Federal Catarinense – Campus Brusque. A solução proposta opera em duas camadas integradas: um Data Plane nativo no Kernel Linux utilizando eBPF/XDP (eXpress Data Path) para descarte imediato de pacotes maliciosos via instrução XDP_DROP na camada de enlace/driver, e um Control Plane alimentado por um motor preditivo neural espaço-temporal (STGNN). A arquitetura neural combina Convoluções 1D (CNN-1D) para extração de padrões temporais sobre os atributos mais correlacionados (selecionados via método de Pearson), redes de memória de longo e curto prazo (LSTM) e camadas de Atenção em Grafo (GATConv) para modelar as dependências topológicas da rede de computadores, onde os nós representam endereços IP e as arestas correspondem aos fluxos de tráfego ativos. Avaliada experimentalmente na proporção de 80% para treinamento/validação e 20% para teste independente, a arquitetura alcançou F1-Score empírico de 0,7500 (75,00%), Precisão de 66,67%, Revocação de 85,71% e latência preditiva de 1,82 ms por lote relacional. Os resultados demonstram a viabilidade técnica do sistema para o monitoramento contínuo de redes sem causar degradação no desempenho do tráfego legítimo.

Palavras-chave: Segurança de Redes; eBPF/XDP; Redes Neurais em Grafo; Aprendizado Profundo; Detecção de Intrusão.

1. INTRODUÇÃO

A sofisticação das ameaças cibernéticas contemporâneas impõe desafios críticos às infraestruturas de TI. Ataques distribuídos de negação de serviço (DDoS), varreduras de portas ativas (port scanning) e movimentação lateral executados por malwares modernos exploram lacunas na visibilidade relacional dos analisadores de tráfego convencionais (JULISH, 2002; SARHAN et al., 2021).

Os Sistemas de Detecção de Intrusão tradicionais baseados em assinaturas ou modelos estatísticos simplificados atuam frequentemente na camada de aplicação ou utilizam capturas de pacotes via sockets brutos (raw sockets) que sofrem com elevado custo computacional e latência decorrente do percurso completo na pilha TCP/IP do kernel. Além disso, falham em capturar as dependências topológicas entre múltiplos endereços IP ativos na rede.

Para superar essas limitações, este artigo apresenta o projeto **SPECTRE_GRID**, desenvolvido no Instituto Federal Catarinense – Campus Brusque vinculadamente ao Projeto PVE2957-2025 ("IDS Deep Learning"). O sistema combina mitigação imediata de pacotes maliciosos na camada de enlace/driver do Linux via *eBPF/eXpress Data Path (XDP)* com um motor preditivo neural espaço-temporal (STGNN) constituído por Convolução 1D, rede LSTM e Mecanismo de Atenção em Grafo (GATConv).

2. FUNDAMENTAÇÃO TEÓRICA E TRATAMENTO DE DADOS

2.1 Seleção de Atributos por Correlação de Pearson

Com base nas recomendações de Pouyanfar et al. (2018) e Sarhan et al. (2021), a redução de dimensionalidade é essencial para viabilizar inferências neurais de baixa latência em tempo real. No **SPECTRE_GRID**, a seleção dos Top-20 atributos é realizada através do cálculo da correlação linear de Pearson absoluta com a variável alvo binária y :

$$r_{x,y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$


2.2 Normalização Z-Score com StandardScaler

Os atributos selecionados são submetidos ao processo de padronização escalar Z-Score através do algoritmo *StandardScaler* (WITTEN et al., 2016), garantindo média zero ($\mu = 0$) e variância unitária ($\sigma^2 = 1$):

$$z = \frac{x - \mu}{\sigma}$$

3. ARQUITETURA DO SPECTRE_GRID

Quadro 1 – Arquitetura de Componentes do SPECTRE_GRID



Fonte: Os autores (2026).

O Data Plane executa diretamente no espaço de kernel através do programa compilado

```
ebpf/spectre_xdp.c
```

, consultando as estruturas *flow_map* e *block_map* para descartar pacotes nocivos via instrução

```
XDP_DROP
```

antes da alocação de memória no buffer do sistema.

4. RESULTADOS EXPERIMENTAIS E DISCUSSÃO

Os experimentos de validação empírica foram conduzidos em bancada de testes no IFC Campus Brusque utilizando divisão metodológica de 80% dos nós do grafo para treinamento e validação, reservando 20% para a avaliação de teste independente.

Tabela 1 – Métricas Empíricas de Desempenho no Conjunto de Teste (20%)

Métrica de Avaliação	Valor Empírico Obtido	Descrição do Resultado
Acurácia (Accuracy)	0,6000 (60,00%)	Proporção global de classificações corretas no lote de teste.
Precisão (Precision)	0,6667 (66,67%)	Taxa de acerto entre os alertas positivos emitidos pelo modelo.
Revocação (Recall)	0,8571 (85,71%)	Capacidade de detecção dos nós realmente infectados por ameaças.
F1-Score	0,7500 (75,00%)	Média harmônica entre Precisão e Revocação no conjunto de teste.
Latência de Inferência	1,82 ms	Tempo médio gasto no forward pass neural por lote relacional.

Fonte: Dados experimentais obtidos pelos autores (2026).

A latência preditiva alcançada de **1,82 ms** demonstra a viabilidade operacional do SPECTRE_GRID para atuar de forma acoplada ao daemon de controle em tempo real, permitindo a identificação e o bloqueio proativo de anomalias sem comprometer a vazão do canal.

5. CONCLUSÃO E TRABALHOS FUTUROS

Este artigo apresentou a concepção e validação experimental do SPECTRE_GRID para a IX FACCHU 2026. A integração entre a filtragem ultrarrápida no kernel Linux (eBPF/XDP) e a modelagem espacial-temporal por Redes Neurais em Grafo (STGNN) comprova a eficiência da arquitetura para a cibersegurança moderna.

Como trabalhos futuros do Projeto PVE2957-2025, inclui-se a implementação da normalização dinâmico-online pelo Algoritmo de Welford sem dependência estática de lote e o retreinamento massivo na base completa NF-UQ-NIDS-v2 em ambiente distribuído.

REFERÊNCIAS

CHOLLET, F. **Deep Learning with Python**. Manning Publications, 2018.

JULISH, K. Data Mining for Intrusion Detection. **Applications of Data Mining in Computer Security**, Advances in Information Security, vol. 5, pp. 33–65, 2002.

MALLMANN, J. et al. PPCensor: An Architecture for Real-time Pornography Detection in Video Streaming. **Future Generation Computer Systems (FGCS)**, PUCPR & IFC, 2021.

POUYANFAR, S. et al. A Survey on Deep Learning: Algorithms, Techniques, and Applications. **ACM Comput. Surv.**, vol. 51, no. 5, 2018.

SARHAN, M. et al. Towards a Standard Feature Set for Network Intrusion Detection Datasets (NF-UQ-NIDS-v2). **IEEE Access**, v. 9, p. 166820-166831, 2021.

VELIČKOVIĆ, P. et al. Graph Attention Networks (GATConv). **ICLR**, 2018.

WITTEN, I. H. et al. **Practical Machine Learning Tools and Techniques**. Editora Morgan Kaufmann, 4th Edition, 2016. ISBN: 9780128042915.